

Práctica 1
***Identificación de equipos de fútbol
mediante histogramas***

Gonzalo Solera
Joan Saltó
Facultat d'Informàtica de Barcelona

6 de abril de 2018

Índice

1. Introducción	3
2. Objetivos de la práctica	3
3. Experimentos realizados	3
4. Algoritmo implementado	6
5. Resultados obtenidos	8
5.1. Falsos negativos	8
5.2. Falsos positivos	10
6. Valoraciones extra	13
7. Código de terceros	13

1. Introducción

2. Objetivos de la práctica

El objetivo de esta práctica es identificar de forma automática las imágenes en las que se detecte la presencia de camisetas del F.C. Barcelona. A partir de un dataset dado de 7 equipos se pedía clasificar cada imagen en función de si aparecía una camiseta del Barça en ella.

Vamos a explicar los intentos iniciales realizados, incluyendo por qué funcionaron mal. Y posteriormente detallaremos el algoritmo utilizado final.

3. Experimentos realizados

El primer intento y el más simple de ellos se hacía sobre el espacio RGB. Consistía en, primero de todo, normalizar la luz de las imágenes por RGB o HSV, siguiendo el procedimiento visto en clase. Posteriormente extrajimos 3 histogramas de cada imagen, uno por cada componente. Estos histogramas tienen que estar normalizados, de forma que la suma de todos los bins sea igual a 1 independientemente del tamaño de la imagen. Para comparar una imagen con el modelo (con el cual obviamente hemos extraído los histogramas de la misma forma), comparábamos los histogramas de cada componente por separado. En el caso en que la luz se haya normalizado por RGB, solo hacía falta comparar los histogramas R y B. Se puede seleccionar qué algoritmo se utilizaba para comparar los histogramas, entre los cuales se encontraba la distancia Euclídea y el chi-squares.

En ambos casos, el resultado no era malo pero creíamos que era mejorable. Hay que destacar que siguiendo esta estrategia, se pierde información valiosa al extraer los histogramas por separado. Seguramente se habría obtenido mejores resultados si hubiéramos extraído un único histograma de 3 o 4 dimensiones en vez de uno por cada componente. De todas formas conseguimos resultados muy buenos en espacio HSV así que no llegamos a experimentar esa posibilidad.

El primer intento en HSV consistió en normalizar la luz por HSV. Posteriormente, extraer un único histograma (normalizado) de 3 dimensiones con las componentes H y S. Enseguida vimos la utilidad de este espacio de color ya que cada color diferente se encontraba en una región diferente del histograma, siendo muy fácilmente identificables. De esta forma, el histograma extraído de la imagen modelo era claramente reconocible como el histograma de una camiseta del Barcelona, ya que en las regiones rojas y azules había dos picos muy grandes, como se puede apreciar en la siguiente imagen:




Figura 1: Histograma HSV del modelo

Igual que antes, se podían comparar los histogramas de la imagen actual con la del modelo usando los procedimientos mencionados anteriormente: Dist. euclídea y chi-squares. El chi-squares funcionaba mejor pero aún así el resultado no era óptimo. Pudimos ver un caso en el que este método funcionaba mal:

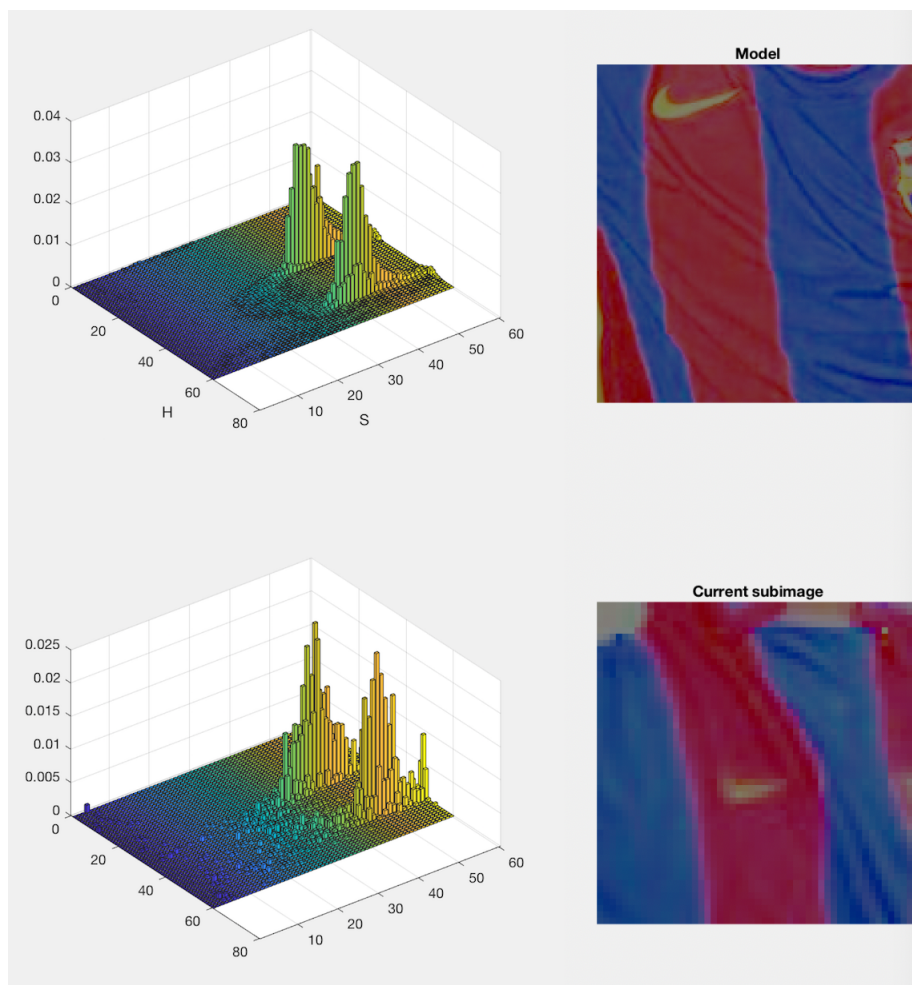


Figura 2: Caso problemático comparando histogramas de HSV

En ambos histogramas (modelo y imagen actual) se puede apreciar claramente como hay dos picos muy parecidos en las regiones azul y roja, ya que efectivamente aparecen camisetas del Barcelona en ambas imágenes. Sin embargo, los métodos para comparar los dos histogramas sacaban una diferencia muy elevada. Esto se debe a que estos métodos comparan 'bin' con 'bin', y los dos picos no están perfectamente centrados.

Para solucionar este comportamiento, probamos a hacer dos cosas: Desplazar varias veces el modelo para intentar 'ajustarlo' a la imagen actual (aumentaba mucho el coste computacional). También probamos a realizar una convolución a los histogramas obtenidos, de forma que se suavizaban los bordes de los picos, consiguiendo mejores resultados en la comparación como se puede ver a

continuación:

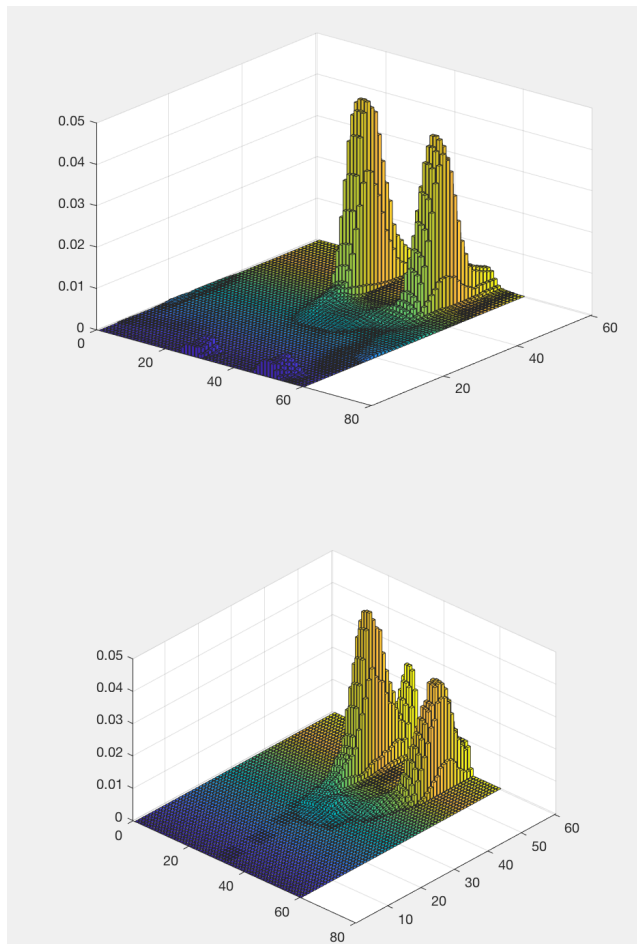


Figura 3: Resultado de aplicar una convolución a los histogramas HSV

De todas formas, el resultado fue mejorado por la siguiente y definitiva estrategia.

4. Algoritmo implementado

El código lo hemos estructurado de forma que se permita utilizar distintas funciones en cada paso, consiguiendo que definiendo unas variables en el main.m se utilicen unas u otras.

De esta forma, la versión final utilizará por defecto el algoritmo que mejor ha funcionado pero el usuario puede cambiarlo o modificar los thresholds cambian-

do las primeras variables del main. De forma que los experimentos explicados anteriormente están incluidos en el código. La estrategia óptima que explicamos en este apartado es la que está activada por defecto.

Como con el último experimento explicado, este algoritmo final también trabaja sobre el espacio de color HSV. Primero realiza una normalización de luz por HSV. Después extrae subimágenes cuadradas no-solapadas de la imagen a analizar de tamaño 50x50. Genera el histograma (normalizado) de 3 dimensiones de la componente H y S con tamaño de bin 1/60 (60 bins). Posteriormente desplaza un poco el histograma obtenido para que la región del color rojo quede junta (ya que la variable es circular). Estos pasos son comunes con el experimento anterior. La gran diferencia es en cómo compara los histogramas entre sí. Nos dimos cuenta de que manualmente eramos capaces de clasificar imágenes observando este histograma fácilmente, y que las funciones chi-square y distancia euclídea no lo conseguían porque comparaban bin por bin. Para poder implementar el proceso que nosotros realizábamos de forma intuitiva nos hemos creado nuestra propia función comparadora de histogramas. Consiste en simplemente sumar las bins de dos regiones del histograma: la región azul y roja por separado. Esta región (en donde también se recorta por el nivel de saturación) fue escogida sobre el histograma de la imagen modelo.

La suma de bins de estas dos regiones equivalen a la cantidad (normalizada) de píxeles de dichas regiones:

$$\text{red_count} = \sum_{i=25}^{35} \sum_{j=20}^{60} \text{im_hist}[i, j]$$

$$\text{blue_count} = \sum_{i=45}^{52} \sum_{j=20}^{60} \text{im_hist}[i, j]$$

Definimos la diferencia de la subimagen actual respecto al modelo como:

$$\begin{aligned} \text{diff}_1 &= 8 * (\text{red_count} - \text{blue_count})^2 \\ \text{diff}_2 &= 1 - (\text{red_count} + \text{blue_count}) \\ \text{diff} &= \text{diff}_1 + \text{diff}_2 \end{aligned}$$

Básicamente lo que busca esta métrica es considerar que una subimagen es del Barcelona solo si diff_1 y diff_2 son ambas bajas. diff_1 es baja si la cantidad de píxeles de las dos regiones es similar (sin importar la cantidad en sí). diff_2 valora que las dos regiones HSV sean mayoritarias en la imagen. Efectivamente, si una imagen tiene una cantidad de píxeles rojos y azules parecidos, pero la mayoría de píxeles pertenecen a otras regiones HSV, la diferencia será alta debido a diff_2 . Si por el contrario, hay una gran cantidad de píxeles de los colores de la camiseta del Barcelona pero no están equilibrados (hay mucho más rojo que azul por ejemplo), entonces la diferencia se verá penalizada por diff_1 .

La subimagen se considera del Barcelona si su diferencia 'diff' está por debajo de 0,5. Una imagen se considera del Barcelona si tiene alguna subimagen con diferencia menor que dicho threshold. El histograma del propio modelo tiene una diferencia de 0,0821 siguiendo esta métrica.

5. Resultados obtenidos

En total el algoritmo se ha ejecutado con 309 imágenes, contando las añadidas por nosotros.

Sobre el dataset original (sin las añadidas), se obtiene un 0.925 de acierto contando todas las imágenes. Únicamente sobre las del Barcelona, se clasifican correctamente 0.872. Y dentro de solo las demás, se clasifican correctamente 0.933.

En las ejecuciones con todas las imágenes (incluyendo las añadidas por nosotros), obtenemos un acierto general de 0.913. Contando solo las del Barcelona, un acierto de 0.86, y contando solo las demás, 0.9231.

5.1. Falsos negativos

Los falsos negativos son imágenes del F.C. Barcelona que han sido clasificadas erróneamente. A continuación analizamos unos ejemplos:

La imagen 09 del Barcelona nos produce falso negativo debido a que la mínima diferencia hallada en el total de 30 subimágenes tratadas es de 0.5161, no lo suficientemente baja para considerarse parecido al modelo, ya que el threshold está fijado en 0.5.

La imagen 15 del Barcelona es un falso negativo porque la imagen es demasiado pequeña y las subimágenes no llegan a encajar bien con la camiseta.

La imagen 19 del Barcelona es también mal clasificada porque el pantalón azul tan visible hace que la región roja sea más pequeña en proporción que la azul, provocando que la diferencia de todas las subimágenes sea demasiado elevada.



Figura 4: FC Barcelona 19

La imagen 32 es un falso negativo por una razón similar a la anterior: La camiseta no es la tradicional, y hace que todas las subimágenes tengan mucho más rojo que azul por lo que el clasificador las penalizará.



Figura 5: FC Barcelona 32

La imagen 38 del Barcelona nos produce un falso negativo porque ninguna subimágen encaja correctamente con la camiseta. En todas aparece mucho fondo, lo cual hace que el clasificador lo penalice (porque la región roja + azul no es mayoritaria en las subimágenes)



Figura 6: FC Barcelona 38

La imagen 44 del Barcelona es un falso negativo porque la mínima diferencia de una subimagen es de 0.553. Los brazos cruzados afectan mucho ya que no hay subimágenes que encuadren una camiseta sin gran proporción de carne.



Figura 7: FC Barcelona 44

5.2. Falsos positivos

Los falsos positivos son imágenes pertenecientes al resto de equipos que sabemos debería dar negativo pero ha resultado positivo.

La imagen 05 del Milan nos produce un falso positivo debido a que la mínima diferencia hallada en una subimagen de las tratadas es de 0.4794 (pasando el threshold por muy poco). La subimagen con esta diferencia tan baja es una que incluye el pantalón negro, el cual, al normalizar la luz se convierte en azul. En combinación con las rallas rojas de la camiseta, el clasificador se equivoca.



Figura 8: AC Milan 05

La imagen 06 del Chelsea se clasifica erróneamente porque hay una subimagen en la que aparece una camiseta azul de un jugador y otra roja de otro jugador.



Figura 9: Chelsea 06

La imagen 17 de la Juventus también se clasifica mal porque en el panel de anuncios aparecen franjas rojas y azules.



Figura 10: Juventus 17

La imagen 13 perteneciente al Liverpool produce un falso positivo producido por el fondo ya que hay un cartel azul y la equipación es roja con un valor de diferencia mínimo hallado de 0.3792.



Figura 11: Liverpool 13

En la imagen 26 Madrid la mínima diferencia es de 0.4997, la cual está muy cerca del threshold.

En la imagen 02 del RCD Español se produce un falso positivo porque hay una subimagen que incluye el logo rojo de la camiseta con el fondo azul.



Figura 12: RCD Español 02

6. Valoraciones extra

Con el objetivo de valorar cómo nuestro modelo generaliza con un test set con el que no ha sido 'entrenado', hemos añadido las siguiente imágenes:

- 10 imágenes más del F.C. Barcelona
- 10 imágenes de la Roma
- 10 imágenes del RCD Español

7. Código de terceros

No hemos utilizado código de fuera de Matlab, solo funciones de la propia librería de Matlab.